

Propuesta de metodología de clasificación de objetos basado en técnicas de Deep Learning usando datos multi-vista

Andrés Cruz y Corro Armenta
acruzycorro@inaoep.mx¹

Instituto Nacional de Astrofísica, Óptica y Electrónica

Enero 2019

¹Instituto Nacional de Astrofísica, Óptica y Electrónica 

Introducción

Tesis

Cruz y Corro

Las plataformas satelitales y aéreas actuales proveen de valiosos datos hiperspectrales para el análisis de imágenes en áreas tan distintas como la agricultura [12], mineralogía [15], física [5], astronomía [7] y ciencias ambientales [14, 2].

En todos estos campos (entre otros) se desea hacer cierta clasificación a nivel de píxeles y extraer después *features*.

Problemática (1)

Tesis

Cruz y Corro

Sin embargo, los datos hiperespectrales sufren de varias desventajas, principalmente [3]:

- ① Alta dimensionalidad,
- ② Variaciones espaciales en la firma espectral,
- ③ Alto costo de etiquetado² para las muestras, y
- ④ La variación en la calidad de los datos de entrada

²Ya sea en tiempo de entrenamiento o clasificación de datos de entrenamiento [6]

Problemática (2)

Tesis

Cruz y Corro

Por otro lado, el análisis y adquisición usual de imágenes sufren de los siguientes problemas:

- ① Relativa baja resolución espacial (para imágenes satelitales)³
- ② Dependencia de datos *raster* para producir objetos vectoriales en Sistemas de Información Geográfica [6]
- ③ Alto tiempo de respuesta/toma de decisiones

³Por ejemplo, en [4, p.2099] se tiene una resolución espacial de 18m. ↻ 🔍

Objetivos

Tesis

Cruz y Corro

General

Presentar una metodología de análisis de imágenes con base en datos multi-vista usando técnicas de Deep Learning que permita el uso de materiales de bajo costo y corto tiempo de respuesta para la toma de decisiones.

Objetivos

Tesis

Cruz y Corro

Particulares

- 1 Generar un procedimiento de análisis de imágenes obtenidas desde una plataforma de baja altitud y alta resolución espacial,

Objetivos

Tesis

Cruz y Corro

Particulares

- ① Generar un procedimiento de análisis de imágenes obtenidas desde una plataforma de baja altitud y alta resolución espacial,
- ② Analizar la viabilidad del uso de cámaras de bajo costo para la obtención de datos multi-vista

Objetivos

Tesis


Cruz y Corro

Particulares

- ① Generar un procedimiento de análisis de imágenes obtenidas desde una plataforma de baja altitud y alta resolución espacial,
- ② Analizar la viabilidad del uso de cámaras de bajo costo para la obtención de datos multi-vista
- ③ Analizar la precisión del procedimiento propuesto en la detección y monitoreo de especies invasivas en cultivos de interés comercial

Se han usado las siguientes técnicas:

- Romero, Gatta y Camps-Valls [16]: Uso de pre-entrenamiento en redes convolucionales para extracción de *features* en imágenes satelitales;
- Chen *et al.* [4]: Clasificación de imágenes satelitales usando técnicas de *Deep Learning*⁴
- Kussul *et al.* [11]: Clasificación de cultivos mediante imágenes satelitales usando redes neuronales multinivel;
- Liu *et al.* [13]: Extracción de datos multi-vista desde baja altitud (300 m) y con alta resolución espacial (6.2 cm/pixel);

⁴Auto-Encoders y Stacked Auto-Encoder 

Estado de la técnica

Tesis

Cruz y Corro

- Yongliang *et al.* [18]: Uso de redes neuronales para análisis y clasificación de tatuajes;
- Zhou *et al.* [19]: Análisis de imágenes médicas mediante redes imagen-a-imagen;
- Avendi, Jafarkhani y Kheradvar [1]: Segmentación de imágenes cardíacas y obtención de regiones de interés médico;
- Tappen *et al.* [17]: Entrenamiento de redes neuronales con *clusters* de etiquetas o categorías;

Metodología (1)

Tesis

Cruz y Corro

Evaluación de clasificadores (según estado del arte):

- Random Forest (un “promedio” de varios árboles de decisión),

Metodología (1)

Tesis

Cruz y Corro

Evaluación de clasificadores (según estado del arte):

- Random Forest (un “promedio” de varios árboles de decisión),
- Support Vector Machine (definición de hiper-planos),

Metodología (1)

Tesis

Cruz y Corro

Evaluación de clasificadores (según estado del arte):

- Random Forest (un “promedio” de varios árboles de decisión),
- Support Vector Machine (definición de hiper-planos),
- Fully Convolutional Network ,

Metodología (1)

Tesis

Cruz y Corro

Evaluación de clasificadores (según estado del arte):

- Random Forest (un “promedio” de varios árboles de decisión),
- Support Vector Machine (definición de hiper-planos),
- Fully Convolutional Network ,
- Deep-Convolutional Neural Network

Metodología (2)

Tesis

Cruz y Corro

Generación de datos multi-vista

- Calibración de cámara

Generación de datos multi-vista

- Calibración de cámara
- Proyección de coordenadas-imagen a coordenadas-DSM (4 pasos, véase Liu *et al.* [[13](#)])

Metodología (3)

Tesis

Cruz y Corro

- Modelado de terreno vía BDRF⁵ para generar clasificaciones
- (Pre-)Entrenamiento de una Red Neuronal, usando los clasificadores descritos

⁵*Bidirectional Reflectance Distribution Function*

Evaluación de clasificadores (1)

Tesis

Cruz y Corro

Lenguaje de programación Python 3.x

Ambiente de desarrollo Jupyter Notebook

Análisis y creación de NN OpenCV, keras, scikit-learn y
TensorFlow

Evaluación de clasificadores (2)

Tesis

Cruz y Corro

Resultados preliminares en clasificación de *datasets* similares [9, 8]

Single Decision Tree Precisión: 47 %

Random Forest Precisión 87.1 %, error 0.05

Multi-level perceptron Precisión 90 %, error 0.09

2-D Convolutional Layer (keras) Precisión: 98 %, error 0.03

Clasificación en categorías

Tesis

Cruz y Corro

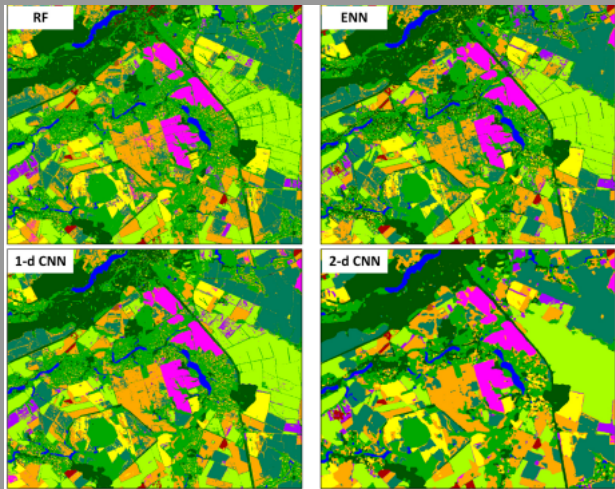


Figura1: Ejemplo de áreas clasificadas, de Kussul *et al.* [11]

Reconstrucción de imágenes

Tesis

Cruz y Corro



Figura2: Ejemplos de datos multi- vista para reconstruir una escena, de Koukal, Atzberger y Schneider [10]

Generación de clasificaciones con datos multi-vista

Tesis

Cruz y Corro

- ① Selección de muestra (ortoimágenes)
- ② Extracción de *features*:
 - Espectrales
 - De textura (máximos, mínimos, desviaciones. . .) Liu *et al.* [13, p.8-12]
- ③ Generación de clasificadores:
 - Desde características espectrales,
 - Desde características texturales,
 - Desde reconstrucción de imagen via BRDF (véase Koukal, Atzberger y Schneider [10])
- ④ Validación cruzada con todos los experimentos

Reducción de dimensionalidad con *k*-clustering

Tesis

Cruz y Corro

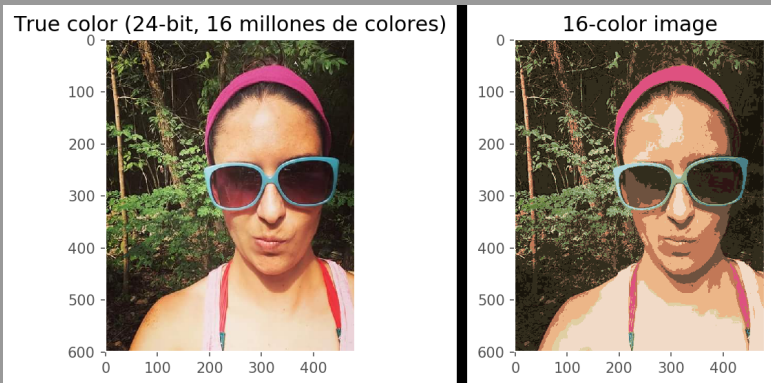


Figura3: Ejemplo de reducción de dimensionalidad con clustering

Reducción de dimensionalidad

Tesis

Cruz y Corro




Figura4: Ejemplo de reducción de dimensionalidad con clustering

Referencias y bibliografía I

Tesis

Cruz y Corro

- [1] Michael Rashidi Avendi, Hamid Jafarkhani y Arash Kheradvar. "Automated segmentation of organ chambers using deep learning methods from medical imaging". US20170109881A1. University of California. 2017. URL: <https://patents.google.com/patent/US20170109881A1> (visitado 20-11-2018).
- [2] Jose M. Bioucas-Dias *et al.* "Hyperspectral Remote Sensing Data Analysis and Future Challenges". En: *IEEE Geoscience and Remote Sensing Magazine* 1.2 (jun. de 2013), págs. 6-36. DOI: [10.1109/mgrs.2013.2244672](https://doi.org/10.1109/mgrs.2013.2244672).

Referencias y bibliografía II

Tesis

Cruz y Corro

- [3] G. Camps-Valls y L. Bruzzone. “Kernel-based methods for hyperspectral image classification”. En: *IEEE Transactions on Geoscience and Remote Sensing* 43.6 (jun. de 2005), págs. 1351-1362. DOI: [10.1109/tgrs.2005.846154](https://doi.org/10.1109/tgrs.2005.846154).
- [4] Yushi Chen et al. “Deep Learning-Based Classification of Hyperspectral Data”. En: *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 7.6 (jun. de 2014), págs. 2094-2107. DOI: [10.1109/jstars.2014.2329330](https://doi.org/10.1109/jstars.2014.2329330).
- [5] Ray Egerton. *Electron Energy-Loss Spectroscopy in the Electron Microscope*. Springer US, 29 de jul. de 2011. URL: https://www.ebook.de/de/product/16829983/ray_egerton_electron_energy_loss_spectroscopy_in_the_electron_microscope.html.

Referencias y bibliografía III

Tesis

Cruz y Corro

- [6] G. J. Hay y G. Castilla. “Geographic Object-Based Image Analysis (GEOBIA): A new name for a new discipline”. En: *Lecture Notes in Geoinformation and Cartography*. Springer Berlin Heidelberg, 2008, págs. 75-89. ISBN: 978-3-540-77057-2. DOI: [10.1007/978-3-540-77058-9_4](https://doi.org/10.1007/978-3-540-77058-9_4). URL: <https://www.amazon.com/Object-Based-Image-Analysis-Knowledge-Driven-Geoinformation/dp/3540770577?SubscriptionId=AKIAIOBINVZYXZQZ2U3A&tag=chimbori05-20&linkCode=xm2&camp=2025&creative=165953&creativeASIN=3540770577>.
- [7] E. Keith Hege *et al.* “Hyperspectral imaging for astronomy and space surveillance”. En: *Imaging Spectrometry IX*. Ed. por Sylvia S. Shen y Paul E. Lewis. SPIE, ene. de 2004. DOI: [10.1117/12.506426](https://doi.org/10.1117/12.506426).

Referencias y bibliografía IV

Tesis

Cruz y Corro

- [8] Brian A. Johnson. “High-resolution urban land-cover classification using a competitive multi-scale object-based approach”. En: *Remote Sensing Letters* 4.2 (feb. de 2013), págs. 131-140. DOI: [10.1080/2150704x.2012.705440](https://doi.org/10.1080/2150704x.2012.705440).
- [9] Brian Johnson y Zhixiao Xie. “Classifying a high resolution image of an urban area using super-object information”. En: *ISPRS Journal of Photogrammetry and Remote Sensing* 83 (sep. de 2013), págs. 40-49. DOI: [10.1016/j.isprsjprs.2013.05.008](https://doi.org/10.1016/j.isprsjprs.2013.05.008).
- [10] Tatjana Koukal, Clement Atzberger y Werner Schneider. “Evaluation of semi-empirical BRDF models inverted against multi-angle data from a digital airborne frame camera for enhancing forest type classification”. En: *Remote Sensing of Environment* 151 (ago. de 2014), págs. 27-43. DOI: [10.1016/j.rse.2013.12.014](https://doi.org/10.1016/j.rse.2013.12.014).

Referencias y bibliografía V

Tesis

Cruz y Corro

- [11] Nataliia Kussul *et al.* “Deep Learning Classification of Land Cover and Crop Types Using Remote Sensing Data”. En: *IEEE Geoscience and Remote Sensing Letters* 14.5 (mayo de 2017), págs. 778-782. DOI: [10.1109/lgrs.2017.2681128](https://doi.org/10.1109/lgrs.2017.2681128).
- [12] F. M. Lacar, M. M. Lewis e I. T. Grierson. “Use of hyperspectral imagery for mapping grape varieties in the Barossa Valley, South Australia”. En: *IGARSS 2001. Scanning the Present and Resolving the Future. Proceedings. IEEE 2001 International Geoscience and Remote Sensing Symposium (Cat. No.01CH37217)*. IEEE, 13 de jul. de 2001. DOI: [10.1109/igarss.2001.978191](https://doi.org/10.1109/igarss.2001.978191).

Referencias y bibliografía VI

Tesis

Cruz y Corro

- [13] Tao Liu *et al.* “Evaluating the potential of multi-view data extraction from small Unmanned Aerial Systems (UASs) for object-based classification for Wetland land covers”. En: *GIScience & Remote Sensing* (jul. de 2018), págs. 1-30. DOI: [10.1080/15481603.2018.1495395](https://doi.org/10.1080/15481603.2018.1495395).
- [14] Tim J. Malthus y Peter J. Mumby. “Remote sensing of the coastal zone: An overview and priorities for future research”. En: *International Journal of Remote Sensing* 24.13 (ene. de 2003), págs. 2805-2815. DOI: [10.1080/0143116031000066954](https://doi.org/10.1080/0143116031000066954).
- [15] Freek van der Meer. “Analysis of spectral absorption features in hyperspectral imagery”. En: *International Journal of Applied Earth Observation and Geoinformation* 5.1 (feb. de 2004), págs. 55-68. DOI: [10.1016/j.jag.2003.09.001](https://doi.org/10.1016/j.jag.2003.09.001).

Referencias y bibliografía VII

Tesis

Cruz y Corro

- [16] Adriana Romero, Carlo Gatta y Gustau Camps-Valls. “Unsupervised Deep Feature Extraction for Remote Sensing Image Classification”. En: *IEEE Transactions on Geoscience and Remote Sensing* 54.3 (mar. de 2016), págs. 1349-1362. DOI: [10.1109/tgrs.2015.2478379](https://doi.org/10.1109/tgrs.2015.2478379).
- [17] Marshall Friend Tappen *et al.* “Cluster-trained machine learning for image processing”. US9704054B1. Amazon Technologies Inc. 2017. URL: <https://patents.google.com/patent/US9704054B1> (visitado 20-11-2018).

Referencias y bibliografía VIII

Tesis

Cruz y Corro

- [18] Zhang Yongliang *et al.* "Tattoo image classification method based on deep learning". CN103996056A. Machine-translated by Google. 2014. URL: <https://patents.google.com/patent/CN103996056A/en?q=deep+learning&q=image&q=analysis&oq=deep+learning+image+analysis> (visitado 20-11-2018).
- [19] S. Kevin Zhou *et al.* "Deep image-to-image network learning for medical image analysis". US9760807B2. Siemens Healthcare GmbH. 2017. URL: <https://patents.google.com/patent/US9760807B2> (visitado 20-11-2018).